



RouteZone

Application de prédiction de la gravité des accidents de la route

Rapport E1 — Collecte, stockage et mise à disposition des données

Meriem ABDELOUAHED

Formation Développeur en Intelligence Artificielle — Simplon × Microsoft

Titre RNCP37827

github.com/Meriem69/Routezone

Sommaire

1. Contexte et objectif	3
2. Collecte des données	3
3. Nettoyage et préparation	5
4. Base de données PostgreSQL	5
5. API REST Data — FastAPI	7
6. Conclusion	8
Annexe — Figures complémentaires	9
Annexe — Modélisation Merise : MCD, MLD, MPD	15
Annexe — Registre des traitements RGPD	

1. Contexte et objectif

RouteZone est un système de machine learning visant à prédire la gravité d'un accident routier — GRAVE (tué ou hospitalisé) ou PAS GRAVE (indemne ou blessé léger) — à partir des données BAAC (Bulletin d'Analyse des Accidents Corporels) 2022-2024, publiées en open data par le Ministère de l'Intérieur.

Le projet répond à une problématique de sécurité routière : aider les autorités et les services de secours à anticiper les cas critiques pour mieux prioriser les interventions. La spécificité de RouteZone réside dans l'intégration du Golden Hour, principe de traumatologie selon lequel une prise en charge dans les 60 minutes augmente fortement les chances de survie.

Périmètre du Bloc E1 et cheminement

Le Bloc E1 couvre la collecte, la préparation et l'exposition des données. Le travail s'est construit à travers quatre notebooks : notebook_01 (exploration et nettoyage), notebook_02 (enrichissement météo), notebook_03 (scraping ONISR) et notebook_04 (calcul des temps d'intervention OSRM).

Compétence	Action réalisée	Livrable
C1 — Automatiser l'extraction	12 CSV BAAC + API Open-Meteo + scraping ONISR + enrichissement OSRM	4 notebooks + 3 scripts .py
C2 — Sources fiables	Identification et validation des sources open data officielles	Documentation README
C3 — Nettoyage / transformation	Gestion des NaN, des types, des colonnes inutiles, merge des 4 tables	notebook_01 + dataset_clean.csv
C4 — Base de données	Modélisation Merise (MCD/MPD), PostgreSQL 16, scripts d'import	schema_merise.md + create_db.sql
C5 — API REST Data	Développement FastAPI, endpoints documentés sous Swagger	src/api/routes_data.py

2. Collecte des données

La collecte s'appuie sur quatre sources complémentaires : le jeu principal BAAC, deux enrichissements externes (Open-Meteo et ONISR) et un enrichissement calculé via OSRM.

2.1 Données BAAC — notebook_01

Les fichiers BAAC sont organisés en 4 tables liées par la clé Num_Acc : caract (caractéristiques de l'accident), lieux (route, vitesse, surface), usagers (âge, sexe, gravité, équipement) et vehicules (catégorie, type de collision). Au total, 12 fichiers CSV ont été chargés, représentant 153 054 accidents sur 2022-2024, impliquant 413 570 usagers et environ 270 000 véhicules.

```
=== caract 2024 ===
```

	Num_Acc	jour	mois	an	hrmn	lum	dep	com	agg	int	atm	col		adr	lat	long
0	2024000000001	25	3	2024	07:40	2	70	70285	1	1	5	1		D438	47,56277000	6,75832000
1	2024000000002	20	3	2024	15:05	1	21	21054	2	3	7	6		HOTEL DIEU (RUE DE L')	47,02109000	4,83755000

```
=== lieux 2022 ===
```

	Num_Acc	catr	voie	v1	v2	circ	nbv	vosp	prof	pr	pr1	plan	lartpc	larout	surf	infra	situ	vma
0	2022000000001	4	TEIL(vieille route du)	0	NaN	2	2	0	1	(1)	(1)	1	NaN	-1	1	0	1	50
1	2022000000002	4		NaN	0	NaN	2	2	0	1	(1)	(1)	1	NaN	-1	1	0	50

Aperçu des tables BAAC brutes caract et lieux (notebook_01)

2.2 Enrichissement Open-Meteo — notebook_02


La colonne atm du BAAC code la météo de façon déclarative et subjective. L'API Open-Meteo (gratuite, sans clé) fournit la météo réelle heure par heure par coordonnées GPS. L'enrichissement ajoute 4 variables (temperature, precipitation, windspeed, weathercode) via une boucle Python avec une pause de 0,1 s entre requêtes pour respecter l'API. La comparaison entre code déclaré et mesure réelle confirme l'intérêt de l'enrichissement.

2.3 Scraping ONISR — notebook_03

Le baromètre mensuel ONISR (nombre de tués par mois) n'est pas disponible en CSV : il est scrapé avec requests et BeautifulSoup. En inspectant le HTML, j'ai repéré le paramètre d'URL field_annees_target_id qui permet de cibler une année directement, ce qui réduit le nombre de requêtes. Ces données servent ensuite à valider la qualité du dataset BAAC par comparaison des comptages mensuels.

2.4 Enrichissement OSRM — Golden Hour — notebook_04

Le BAAC ne contient aucune information sur le temps d'intervention des secours. J'ai donc intégré cette dimension comme variable explicative. OSRM (Open Source Routing Machine) calcule des itinéraires réels sur le réseau OpenStreetMap, plutôt qu'une distance à vol d'oiseau (Haversine). Le pipeline calcule, pour chaque accident, le trajet depuis la caserne de pompiers la plus proche puis vers le Service d'Accueil des Urgences (SAU), à partir de 5 906 casernes (CIS) et 638 SAU issus de data.gouv.fr. Cette feature deviendra le facteur le plus discriminant du modèle final.



Temps d'intervention des secours cartographié par accident (notebook_04)

2.5 Dictionnaire des données BAAC (fichiers CSV sources)

Les données brutes BAAC sont réparties en quatre fichiers CSV par année, reliés par la clé Num_Acc : CARACTERISTIQUES (circonstances de l'accident), LIEUX (route, vitesse, surface), VEHICULES (catégorie, choc, manœuvre) et USAGERS (âge, sexe, gravité, équipement). La variable id_vehicule relie chaque usager à son véhicule. Le dictionnaire ci-dessous décrit chaque champ et ses principales modalités, d'après le guide officiel ONISR (description des bases BAAC, 23 octobre 2024).

Convention BAAC : la valeur -1 (parfois 0 ou une cellule vide) signifie « non renseigné ». Au nettoyage, ces -1 sont remplacés par NaN puis imputés (mode pour les catégorielles, médiane pour les numériques). Trois variables dérivées sont ajoutées : age, heure et jour_semaine. (en Annexe)

3. Nettoyage et préparation

Le nettoyage suit un principe simple : nettoyer chaque table indépendamment, puis fusionner, pour limiter la propagation d'erreurs. Les NaN ont d'abord été visualisés avec missingno (voir Annexe) pour décider, colonne par colonne, entre suppression et imputation.

3.1 Étapes principales

- Correction du nom de colonne Accident_Id en Num_Acc sur caract 2022 (bug qui aurait cassé les merges).
- Concaténation des 3 années par table ; remplacement des -1 par NaN (convention BAAC : -1 = non renseigné).
- Suppression des doublons stricts ; conversion des types lus comme texte ; correction des coordonnées GPS (virgule en point) et filtrage des DOM-TOM (9 578 lignes retirées).
- Suppression des colonnes à plus de 90 % de NaN ; imputation par le mode (catégorielles) et la médiane (numériques) ; suppression des lignes critiques manquantes (grav, sexe, dep).
- Vérification finale : 0 NaN. Fusion des 4 tables par left join sur Num_Acc. Création de 3 variables dérivées : age, heure, jour_semaine.

3.2 Variable cible et déséquilibre


La colonne grav (1 = indemne, 2 = tué, 3 = hospitalisé, 4 = blessé léger) est binarisée : GRAVE = {2, 3}, PAS GRAVE = {1, 4}. La répartition fait apparaître environ 17 % de cas GRAVE — un déséquilibre des classes décisif pour la modélisation.

3.3 Analyses de biais

Deux analyses de biais assurent une lecture critique : biais de représentation par sexe et biais géographique (volume brut vs taux pour 100 000 habitants, voir Annexe). Elles montrent qu'un volume élevé n'est pas synonyme de risque élevé sans normalisation.

4. Base de données PostgreSQL

La base est modélisée selon la méthode Merise (MCD puis MPD) et implémentée en PostgreSQL 16, choisi pour sa conformité ACID, son support des types géospatiaux, sa gestion de la concurrence (API, scripts d'import et monitoring simultanés) et son intégration avec Docker et SQLAlchemy.



Modèle conceptuel des données (MCD)

Modèle Conceptuel des Données — méthode Merise (schema_merise.md)

La base contient 9 tables en deux groupes : données métier (accidents, lieux, usagers, vehicules, meteo, barometre_onisr, temps_intervention) et données applicatives (users avec mot de passe hashé en bcrypt, predictions avec historique daté). Le script create_db.sql est exécuté automatiquement au démarrage du conteneur PostgreSQL via docker-entrypoint-initdb.d, avec des index sur les colonnes les plus requêtées. Les scripts d'alimentation sont import_data.py (153 054 accidents), collect_meteo.py et scraping_onisr.py. Le MPD et MLD sont en annexes.

5. API REST Data — FastAPI

L'API expose les données via des endpoints REST documentés automatiquement par Swagger UI. Elle est construite avec FastAPI (basé sur Pydantic). En développement, elle est lancée par python -m uvicorn main:app --reload (rechargement automatique du code) ; en production, via Docker, par uvicorn main:app --host 0.0.0.0 --port 8000 (commande définie dans le Dockerfile). L'accès aux données se fait via SQLAlchemy 2.0, qui sépare la logique SQL du code Python et protège contre les injections par le paramétrage des requêtes. L'accès est protégé par clé d'API (X-API-Key) et/ou JWT, avec validation Pydantic et documentation interactive sur /docs et /redoc.

Endpoint	Description
GET /accidents	Liste filtrable des accidents (département, année, gravité)
GET /accidents/stats	Statistiques globales (total, répartition, top départements)
GET /accidents/departement/{dep}	Accidents par département
GET /accidents/gravite	Répartition des usagers par gravité
GET /meteo/stats	Statistiques météo agrégées (Open-Meteo)
GET /onisr/barometre	Baromètre mensuel des tués (ONISR)

API RouteZone 2.0.0 OAS 3.1

openapi.json

API REST du projet RouteZone -- prédiction de gravité des accidents routiers. Certification RNCP37827 Développeur IA Simplon x Microsoft.

Domaines :

- /accidents, /meteo, /onisr -- données BAAC (C5)
- /predict, /predictions -- intelligence artificielle (C8-C9)
- /auth -- authentification JWT

Authentification : header X-API-Key et/ou Authorization: Bearer <JWT>

Autoriser

Authentification

- POSTE** /auth/register Registre
- POSTE** /auth/connexion Se connecter
- POSTE** /auth/token Jeton OAuth2
- OBTENIR** /auth/moi Moi

Donnees BAAC

- OBTENIR** /accidents Liste des accidents
- OBTENIR** /accidents/statistiques Statistiques mondiales
- OBTENIR** /accidents/departement/{dep} Accidents Par Département
- OBTENIR** /accidents/gravite Répartition Gravité
- OBTENIR** /meteo/statistiques Statistiques Météo
- OBTENIR** /onisr/barometre Baromètre Onisr

Documentation interactive Swagger UI exposée sur /docs

6. Conclusion

Le Bloc E1 constitue le socle de données du projet. Livrables produits : dataset nettoyé (153 054 accidents, 413 570 usagers, 0 NaN), dataset enrichi (météo + temps_total_osrm), base PostgreSQL 16 (9 tables, schéma Merise), 4 notebooks documentés et 4 scripts de production, et une API FastAPI documentée sous Swagger.

L'apport différenciant de ce bloc est l'intégration du Golden Hour via OSRM : cette feature dérivée deviendra le facteur le plus discriminant du modèle final. Le dataset enrichi et l'API alimentent le Bloc E3 : entraînement et comparaison de modèles de classification.

Annexe — Figures complémentaires

Figures de cadrage et illustrations détaillées, en complément du corps du rapport.

Fichier CARACTERISTIQUES

Champ	Type	Description et modalités principales
Num_Acc	Texte	Identifiant unique de l'accident. Clé de jointure commune aux 4 fichiers BAAC.
jour / mois / an	Entier	Date de l'accident (jour 1-31, mois 1-12, année).
hrmn	Entier	Heure et minutes au format HHMM. Scindé en heure et minute dans le dataset nettoyé.
lum	Code	Conditions d'éclairage : 1 plein jour, 2 crépuscule/aube, 3 nuit sans éclairage, 4 nuit éclairage non allumé, 5 nuit éclairage allumé.
dep	Texte	Code INSEE du département (2A / 2B pour la Corse).
com	Texte	Code INSEE de la commune.
agg	Code	Localisation : 1 hors agglomération, 2 en agglomération.
int	Code	Type d'intersection : 1 hors intersection, 2 en X, 3 en T, 4 en Y, 5 plus de 4 branches, 6 giratoire, 7 place, 8 passage à niveau, 9 autre. Renommé intersec (mot réservé SQL).
atm	Code	Conditions atmosphériques : 1 normale, 2 pluie légère, 3 pluie forte, 4 neige/grêle, 5 brouillard/fumée, 6 vent fort/tempête, 7 temps éblouissant, 8 couvert, 9 autre.
col	Code	Type de collision : 1 frontale (2 véh.), 2 par l'arrière, 3 par le côté, 4 en chaîne (3+), 5 collisions multiples (3+), 6 autre, 7 sans collision.
adr	Texte	Adresse postale, renseignée surtout en agglomération.
lat / long	Décimal	Coordonnées GPS (WGS84). Virgule décimale convertie en point au nettoyage.

Fichier LIEUX

Champ	Type	Description et modalités principales
Num_Acc	Texte	Identifiant de l'accident (clé étrangère vers CARACTERISTIQUES).
catr	Code	Catégorie de route : 1 autoroute, 2 nationale, 3 départementale, 4 communale, 5 hors réseau public, 6 parc de stationnement, 7 route de métropole urbaine, 9 autre.
voie / v1 / v2	Texte	Numéro de la route et ses indices numérique (v1) et alphanumérique (v2).
circ	Code	Régime de circulation : 1 sens unique, 2 bidirectionnelle, 3 chaussées séparées, 4 voies à affectation variable.
nbv	Entier	Nombre total de voies de circulation.
vosp	Code	Voie réservée : 0 sans objet, 1 piste cyclable, 2 bande cyclable, 3 voie réservée.
prof	Code	Profil en long (déclivité) : 1 plat, 2 pente, 3 sommet de côte, 4 bas de côte.
pr / pr1	Entier	Point de repère de rattachement (pr) et distance en mètres à ce PR (pr1). -1 = non renseigné.
plan	Code	Tracé en plan : 1 rectiligne, 2 courbe à gauche, 3 courbe à droite, 4 en S.
lartpc	Décimal	Largeur du terre-plein central (m), s'il existe.

Champ	Type	Description et modalités principales
larout	Décimal	Largeur de la chaussée affectée à la circulation (m).
surf	Code	État de la surface : 1 normale, 2 mouillée, 3 flaques, 4 inondée, 5 enneigée, 6 boue, 7 verglacée, 8 corps gras/huile, 9 autre.
infra	Code	Aménagement : 0 aucun, 1 tunnel, 2 pont, 3 bretelle, 4 voie ferrée, 5 carrefour aménagé, 6 zone piétonne, 7 péage, 8 chantier, 9 autres.
situ	Code	Situation de l'accident : 1 sur chaussée, 2 BAU, 3 accotement, 4 trottoir, 5 piste cyclable, 6 autre voie spéciale, 8 autres.
vma	Entier	Vitesse maximale autorisée au lieu et au moment de l'accident (km/h).

Fichier VEHICULES


Champ	Type	Description et modalités principales
Num_Acc	Texte	Identifiant de l'accident (clé étrangère).
id_vehicule	Entier	Identifiant unique du véhicule (code numérique), repris pour chaque usager occupant.
num_veh	Texte	Identifiant du véhicule (code alphanumérique).
senc	Code	Sens de circulation : 0 inconnu, 1 repère croissant, 2 décroissant, 3 absence de repère.
catv	Code	Catégorie du véhicule : 01 bicyclette, 02 cyclomoteur, 03 voiturette, 07 VL, 10 VU, 13/14 PL, 30-34 scooters/motos, 37 autobus, 38 autocar, 40 tramway, 50 EDP à moteur (trottinette), 60 EDP sans moteur, 80 VAE, 99 autre.
obs	Code	Obstacle fixe heurté : 0 sans objet, 2 arbre, 3-5 glissières, 6 bâtiment/mur, 8 poteau, 12 bordure de trottoir, 13 fossé/talus, 16 sortie de chaussée sans obstacle.
obsn	Code	Obstacle mobile heurté : 0 aucun, 1 piéton, 2 véhicule, 4 véhicule sur rail, 5 animal domestique, 6 animal sauvage, 9 autre.
choc	Code	Point de choc initial : 1 avant, 2 avant droit, 3 avant gauche, 4 arrière, 7 côté droit, 8 côté gauche, 9 chocs multiples.
manv	Code	Manœuvre principale avant l'accident : 1 sans changement de direction, 9 en s'insérant, 15/16 tournant à gauche/droite, 17/18 dépassant, 23 arrêté, 24 en stationnement, 26 autres.
motor	Code	Type de motorisation : 1 hydrocarbures, 2 hybride électrique, 3 électrique, 4 hydrogène, 5 humaine, 6 autre.
occutc	Entier	Nombre d'occupants dans le transport en commun.

Fichier USAGERS


Champ	Type	Description et modalités principales
Num_Acc	Texte	Identifiant de l'accident (clé étrangère).
id_usager	Entier	Identifiant unique de l'utilisateur (code numérique).
id_vehicule	Entier	Identifiant du véhicule occupé par l'utilisateur (clé étrangère vers VEHICULES).
num_veh	Texte	Identifiant alphanumérique du véhicule occupé.
place	Code	Place occupée dans le véhicule au moment de l'accident. 10 = piéton (non applicable).
catu	Code	Catégorie d'utilisateur : 1 conducteur, 2 passager, 3 piéton.

Champ	Type	Description et modalités principales
grav	Code	VARIABLE CIBLE — Gravité de la blessure : 1 indemne, 2 tué, 3 blessé hospitalisé, 4 blessé léger. Binarisée en GRAVE {2,3} / PAS GRAVE {1,4}.
sexe	Code	Sexe de l'utilisateur : 1 masculin, 2 féminin.
an_nais	Entier	Année de naissance. Sert à dériver l'âge.
trajet	Code	Motif du déplacement : 1 domicile-travail, 2 domicile-école, 3 courses-achats, 4 utilisation professionnelle, 5 promenade-loisirs, 9 autre.
secu1 / secu2 / secu3	Code	Équipements de sécurité utilisés (jusqu'à 3) : 0 aucun, 1 ceinture, 2 casque, 3 dispositif enfants, 4 gilet réfléchissant, 5 airbag (2/3RM), 6 gants (2/3RM), 7 gants+airbag, 8 non déterminable, 9 autre.
locp	Code	Localisation du piéton (sur chaussée, sur passage piéton avec/sans signalisation, trottoir, accotement, refuge).
actp	Code	Action du piéton (se déplaçant dans/contre le sens, traversant, masqué, jouant/courant, montant/descendant d'un véhicule).
etatp	Code	Piéton : 1 seul, 2 accompagné, 3 en groupe.


A1 — Dictionnaire du code des fichiers CSV de la BAAC (notebook_01)




A2 — Météo réelle Open-Meteo selon le code atm déclaré du BAAC (notebook_02)




A3 — Baromètre mensuel des tués scrapé sur l'ONISR (notebook_03)



A4 — Valeurs manquantes visualisées avec missingno (notebook_01)



A5 — Biais géographique : volume brut vs taux corrigé par habitant (notebook_01)



A6 — Répartition de la variable cible grav (notebook_01)

```

caract2022 : 55,302 lignes, 15 colonnes
caract2023 : 54,822 lignes, 15 colonnes
caract2024 : 54,402 lignes, 15 colonnes

lieux2022 : 55,302 lignes, 18 colonnes
lieux2023 : 70,860 lignes, 18 colonnes
lieux2024 : 70,248 lignes, 18 colonnes

usagers2022 : 126,662 lignes, 16 colonnes
usagers2023 : 125,789 lignes, 16 colonnes
usagers2024 : 125,187 lignes, 16 colonnes

vehicules2022 : 94,493 lignes, 11 colonnes
vehicules2023 : 93,585 lignes, 11 colonnes
vehicules2024 : 92,678 lignes, 11 colonnes

```

A5 — Volumes des fichiers BAAC bruts par année


=== usagers 2024 ===

	Num_Acc	id_usager	id_vehicule	num_veh	place	catu	grav	sexe	an_nais	trajet	secu1	secu2	secu3	locp	actp	etatp
0	202400000001	203 988 581	155 781 758	A01	1	1	3	1	2003.0	2	1	-1	-1	-1	-1	-1
1	202400000001	203 988 582	155 781 759	B01	1	1	1	1	1997.0	4	1	-1	-1	-1	-1	-1


=== vehicules 2022 ===

	Num_Acc	id_vehicule	num_veh	senc	catv	obs	obsm	choc	manv	motor	occute
0	202200000001	813 952	A01	1	2	0	2	1	9	1	NaN
1	202200000001	813 953	B01	1	7	0	2	2	1	1	NaN


A7 — Aperçu des tables usagers et vehicules



A8 — Nombre d'accidents par année après nettoyage



A9 — Répartition des accidents par catégorie de route (notebook_01)




A10 — Casernes (CIS) et SAU utilisés pour le calcul OSRM (notebook_04)

Annexe — Modélisation Merise : MCD, MLD, MPD

La base de données RouteZone a été modélisée selon la méthode Merise, en trois niveaux successifs : le MCD (conceptuel, indépendant de toute technologie), le MLD (logique, traduction en tables relationnelles) et le MPD (physique, types et contraintes PostgreSQL).

Modèle Conceptuel des Données (MCD)



Modèle Conceptuel des Données — méthode Merise (schema_merise.md)

Cardinalités :

- **ACCIDENT — LIEU (1,1 / 0,n)** : chaque accident a exactement un lieu ; un lieu peut concerner zéro ou plusieurs accidents.
- **ACCIDENT — USAGER (1,n / 1,1)** : un accident implique au moins un usager ; chaque usager est rattaché à un seul accident.
- **ACCIDENT — VEHICULE (1,n / 1,1)** : au moins un véhicule par accident ; chaque véhicule est concerné par un seul accident.
- **USAGER — VEHICULE (1,1 / 1,n)** : un usager occupe un véhicule ; un véhicule peut transporter plusieurs usagers.
- **ACCIDENT — METEO (0,1 / 1,1)** : la météo enrichie ne couvre pas tous les accidents (GPS manquant ou hors plage) ; une donnée météo correspond à un seul accident.

Le MCD se limite au domaine métier (5 entités). La base physique en compte 9 : les 4 tables supplémentaires (enrichissement et applicatives) sont détaillées dans le MPD ci-dessous.

Modèle Logique des Données (MLD)

Traduction du MCD en tables relationnelles. Clé primaire soulignée, clé étrangère en italique.

ACCIDENT : num_acc, jour, mois, an, heure, minute, lum, agg, intersec, atm, col, lat, long, dep

LIEU : num_acc, catr, circ, nbv, vosp, prof, plan, larrou, surf, infra, situ, vma

VEHICULE : id_vehicule, num_acc, senc, catv, obs, obsm, choc, manv, motor

USAGER : id_usager, num_acc, id_vehicule, place, catu, grav, sexe, an_nais, trajet, secu1, locp, actp, etatp

METEO : id_meteo, num_acc, temperature, precipitation, windspeed, weathercode, source_api, date_collecte

Modèle Physique des Données (MPD)

Le MCD et le MLD ci-dessus décrivent les 5 entités du domaine métier. La base physique PostgreSQL 16 compte 9 tables : aux 5 tables métier s'ajoutent 2 tables d'enrichissement (temps_intervention, barometre_onisr) et 2 tables applicatives (users, predictions).



Clié primaire **soulignée** <pk> · Clé étrangère *italique* <fk> · Variable cible **grav** · PostgreSQL 16

Annexe — Conformité RGPD : registre des traitements et procédure de tri

La base RouteZone contient des données personnelles (comptes utilisateurs et historique de prédictions). Le registre ci-dessous recense l'ensemble des traitements, et la procédure de tri détaille les opérations de conformité et leur fréquence.

Registre des traitements :

Traitement	Données	Finalité	Base légale	Conservation
Compte utilisateur	email, nom (optionnel), mot de passe haché bcrypt	Authentification, accès à l'espace personnel	Consentement (création de compte)	Jusqu'à la suppression faite par l'utilisateur
Historique des prédictions	prédictions horodatées rattachées au user_id	Restitution de l'historique	Consentement	Supprimé avec le compte/purge auto > 12 mois
Données BAAC	Données publiques, sans identifiant personnel direct	Entraînement du modèle, statistiques	Open data / intérêt légitime	Durée du projet
Logs applicatifs	horodatage, niveau, module (aucune donnée personnelle)	Supervision, sécurité	Intérêt légitime	Rotation 30 jours

Procédure de tri et de rétention :

- Données BAAC : open data sans donnée personnelle directe, aucun tri RGPD spécifique.
- Comptes et prédictions : droit à l'effacement (art. 17) via **DELETE /me/predictions** et suppression de compte, immédiate ; droit à la portabilité (art. 20) via **GET /me/predictions/export** au format JSON.
- Purge automatique (rétention) : tâche planifiée mensuelle supprimant les prédictions de plus de 12 mois des comptes inactifs.
- Secrets dans **.env**, jamais versionnés sur Git.